

卷积神经网络

- 一种前馈神经网络
- 受生物学上感受野的机制而提出的

在视觉神经系统中,一个神经元的感受野是指视网膜上的特定区域,只有这个区域的刺激才能够激活该神经元.

卷积神经网络的结构特性

- 局部连接
- 权重共享
- 空间或时间上的次采样


卷积

- 卷积经常用在信号处理上,用于计算信息的延迟累积.
- 假设一个信号发生器每个时刻 t 产生一个信号 x_t ,其信号的衰减率为 w_k ,即在 $k-1$ 个时间步长后,信息为原来的 w_k 倍
- 时刻 t 收到的信号 y_t 为当前时刻产生的信息和以前时刻延迟信息的叠加.

输入信号	接受信号(这里假设衰减率为 0.5)
x_1	$y_1 = x_1$
x_2	$y_2 = x_2 + 0.5x_1$
x_3	$y_3 = x_3 + 0.5x_2 + 0.25x_1$
x_4	...
x_5	...
x_6	...

$$\begin{aligned}
 y_t &= 1 \times x_t + 1/2 \times x_{t-1} + \dots \\
 &= \sum_{k=1}^K w_k x_{t-k+1}
 \end{aligned}
 \tag{1}$$

这里的 w_k 叫做 滤波器 或者是 卷积核 .



如上图所示,下面为输入,上面为卷积输出,其中卷积核要翻转.

卷积尺寸公式

$$H' = \frac{H - K[0] + 2Pad[0]}{S[0]} + 1
 \tag{2}$$

$$W' = \frac{W - K[1] + 2Pad[1]}{S[1]} + 1
 \tag{3}$$

参数说明:

符号	含义
H'	输出的行大小
W'	输出的列大小
S	步长
K	卷积核大小
Pad	填充的大小
H	输入的行大小
W	输入的列大小

Note:一般卷积核大小都是奇数.

卷积类型

1. 窄卷积:步长 $S=1$,两端不补零 $P=0$,输出长度为 $M-K+1$
2. 宽卷积:步长 $S=1$,两端补零 $P=K-1$,输出长度为 $M+K-1$
3. 等宽卷积:步长 $S=1$,两端补零 $P=(K-1)/2$,输出长度为 M

在早期文献中,卷积默认为窄卷积;

在目前文献中,卷积默认为等宽卷积.

卷积的作用

1. 近似微分:当卷积核取一些特殊的值,可以做近似微分
2. 低通滤波/高通滤波: 选取不同的滤波器,可以检测信号中的低频信息或高频信息

互相关

1. 计算卷积需要进行卷积核翻转
2. 卷积操作的目标:提取特征

因此,翻转是不必要的.

于是就有 互相关 .

互相关

$$y_{ij} = \sum_{u=1}^m \sum_{v=1}^n w_{uv} \cdot x_{i+u-1, j+v-1} \quad (4)$$

也就是不翻转.

一般不声明,我们所讲的卷积就是 互相关 .

卷积层的参数

卷积核的参数大小= $K[0] \times K[1] + 1$,其中1来自于偏置项(可以没有)

#####

多个卷积核

1. 卷积核看作一个特征提取器
 1. 如何增强卷积层能力?

引入多个卷积核

池化层

- 卷积层虽然可以显著减少连接的个数,但是每一个特征映射的神经元个数并没有显著减少.

卷积网络结构

卷积网络是由卷积层,池化层,全连接层交叉堆叠而成.

典型结构:

- 趋向于小卷积,大深度(即卷积核大小比较小)
- 趋向于全卷积(就是不池化)

其他卷积种类


空洞卷积

如何增加输出单元的感受野?

- 增加卷积核的大小
- 增加层数来实现
- 在卷积之前进行池化操作


空洞卷积:

- 通过给卷积核插入"空洞"来变相增加其大小.



转置卷积/微步卷积

低维特征映射到高维特征

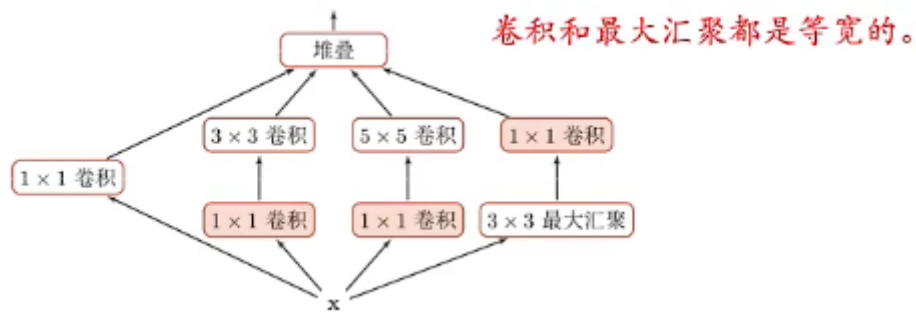


减少卷积核的步数(用小数表示,如0.5步,具体做法是在输入的中间插0实现)

Inception 模块

在卷积网络中,如何设置卷积层的卷积核大小是一个十分关键的问题.

- 在Inception网络中,一个卷积核包含多个不同大小的卷积操作,称为Inception模块.
- Inception模块同时使用 1×1 , 3×3 , 5×5 等不同大小的卷积核,并将得到的特征映射在深度上拼接(堆叠起来)作为输出特征映射.



用多层的小卷积核代替大的卷积核,以减少计算量和参数量.

- 例如,用两层 3×3 的卷积核代替 5×5 的卷积核
- 用连续的 $n \times 1$ 和 $1 \times n$ 来替换 $n \times n$ 的卷积核.

残差网络

残差网络是通过给非线性的卷积层增加 **直连边** 的方式来提高信息传播效率.

- 假设在一个深度网络中,我们期望一个非线性单元(可以为一层或多层的卷积层) $f(x; \theta)$ 去逼近一个目标函数为 $h(x)$
- 将目标函数拆分成两个部分:恒等函数和残差函数

$$h(x) = x + (h(x) - x) \quad (5)$$

其中 $h(x) - x$ 为 $f(x; \theta)$